



**Politechnika
Śląska**

PRACA MAGISTERSKA

System przeznaczony dla osób niewidomych do rozpoznawania dotykanych
obiektów 3D

Piotr MARCOL

Nr albumu: 300463

Kierunek: Informatyka

Specjalność: Oprogramowanie Systemowe

PROWADZĄCY PRACĘ

Dr hab. inż., prof. PŚ Michał Maćkowski

KATEDRA Systemów Rozproszonych i Urządzeń Informatyki

Wydział Automatyki, Elektroniki i Informatyki

Gliwice 2026

Tytuł pracy

System przeznaczony dla osób niewidomych do rozpoznawania dotykanych obiektów 3D

Streszczenie

(Streszczenie pracy – odpowiednie pole w systemie APD powinno zawierać kopię tego streszczenia.)

Słowa kluczowe

(2-5 słów (fraz) kluczowych, oddzielonych przecinkami)

Thesis title

A system designed for the blind to recognize touched 3D objects

Abstract

(Thesis abstract – to be copied into an appropriate field during an electronic submission – in English.)

Key words

(2-5 keywords, separated by commas)

Spis treści

1	Wstęp	1
1.1	Motywacja podjęcia tematu	1
1.2	Cel i zakres pracy	1
1.3	Główne założenia i ograniczenia	1
1.4	Wkład autora	2
1.5	Struktura pracy	2
2	Analiza problemu i przegląd literatury	3
2.1	Perspektywa osób niewidomych w rozpoznawaniu obiektów przestrzennych	4
2.2	Technologie wspomagające osoby z niepełnosprawnością wzroku	8
2.3	Problem rozpoznawania obiektów 3D w interakcji dotykowej	8
2.4	Metody detekcji obiektów w obrazach	8
2.5	Rodzina modeli YOLO	8
2.6	Wykorzystanie danych RGB, głębi i LiDAR w rozpoznawaniu obiektów . .	9
2.7	Metryki oceny detekcji obiektów	9
2.8	Podsumowanie analizy tematu	11
3	Koncepcja systemu rozpoznawania dotykanych obiektów 3D	13
3.1	Założenia funkcjonalne i нефункционалне	13
3.2	Architektura systemu	13
3.3	Dobór klas rozpoznawanych obiektów	13
3.4	Uzasadnienie wyboru metody detekcji	13
3.5	Przepływ danych w systemie	14
3.6	Ograniczenia przyjętej koncepcji	14
4	Implementacja systemu	15
4.1	Środowisko programistyczne i wykorzystane narzędzia	15
4.2	Moduł akwizycji danych obrazowych	15
4.3	Moduł komunikacji klient-serwer	15
4.4	Moduł detekcji obiektów	15
4.5	Moduł informacji zwrotnej dla użytkownika	15

4.6	Organizacja kodu i plików projektu	16
5	Zbiór danych i metodyka badań	17
5.1	Charakterystyka zbioru danych	17
5.2	Proces pozyskiwania i oznaczania danych	17
5.3	Podział danych na zbiory treningowy, walidacyjny i testowy	17
5.4	Warianty danych wejściowych	17
5.5	Konfiguracja treningu modeli	17
5.6	Metryki oceny	18
5.7	Procedura eksperymentalna	18
6	Wyniki badań i ich analiza	19
6.1	Wyniki uczenia modeli YOLO	19
6.2	Porównanie wariantów modeli	19
6.3	Wpływ reprezentacji obrazu na skuteczność detekcji	19
6.4	Analiza błędów klasyfikacji i detekcji	19
6.5	Ocena działania systemu w scenariuszu użytkowym	19
6.6	Dyskusja ograniczeń wyników	20
7	Podsumowanie i wnioski końcowe	21
7.1	Podsumowanie wykonanych prac	21
7.2	Ocena realizacji celu pracy	21
7.3	Najważniejsze wnioski	21
7.4	Możliwe kierunki rozwoju	21
	Bibliografia	24
	Dokumentacja techniczna	27
	Spis skrótów i symboli	29
	Lista dodatkowych plików, uzupełniających tekst pracy (jeżeli dotyczy)	31
	Spis rysunków	33
	Spis tabel	35

Rozdział 1

Wstęp

To powinien być rozdział „ustawiający” całą pracę. Powinny się tu znaleźć:

- kontekst: technologie wspomagające osoby z niepełnosprawnością wzroku,
- problem: rozpoznawanie dotykanych obiektów 3D w czasie zbliżonym do rzeczywistego,
- cel pracy,
- zakres pracy,
- wkład własny,
- krótka charakterystyka rozdziałów.

1.1 Motywacja podjęcia tematu

Tu piszę, dlaczego temat ma sens: samodzielność osób niewidomych, rozpoznawanie obiektów, ograniczenia obecnych rozwiązań.

1.2 Cel i zakres pracy

Cel np.: „Celem pracy jest opracowanie i eksperymentalna ocena systemu wspomagającego rozpoznawanie dotykanych obiektów 3D z wykorzystaniem metod detekcji obiektów na obrazie.”

1.3 Główne założenia i ograniczenia

Tu można wpisać: iPhone jako urządzenie wejściowe, obiekty drukowane 3D, sześć klas, detekcja w obrazie, komunikacja z serwerem, informacja zwrotna audio.

1.4 Wkład autora

Bardzo ważne, bo wymagania tego chcą. Wkład: przygotowanie datasetu, implementacja klienta/serwera, trening modeli, eksperymenty, analiza wyników.

1.5 Struktura pracy

Krótki opis, co jest w każdym rozdziale.

Rozdział 2

Analiza problemu i przegląd literatury

To jest główny wstęp teoretyczny / state of the art. Wymagania mówią wprost, że analiza tematu ma zawierać wprowadzenie do dziedziny, sformułowanie problemu, poszerzone studia literaturowe, przegląd rozwiązań i algorytmów.

Zagadnienie rozpoznawania obiektów przez osoby niewidome wymaga uwzględnienia nie tylko aspektów technicznych, ale też społecznych i psychologicznych – tego, jak użytkownik poznaje otoczenie i jakie informacje z niego wyciąga. Osoby widzące najczęściej nie mają problemów z rozpoznawaniem kształtów, kolorów, orientacji czy położenia obiektów w przestrzeni. Z drugiej strony, osoby niewidome i niedowidzące są zmuszone do korzystania z innych zmysłów, aby zgodnie z nimi móc budować reprezentację otoczenia. Wykorzystują do tego przede wszystkim zmysł dotyku, opis słowny, pamięć oraz wcześniejsze doświadczenia.

Ze względu na to, projektowanie i wykonanie systemu rozpoznawania obiektów nie może skupiać się wyłącznie na aspektach technicznych, ale należy również uwzględnić perspektywę użytkownika docelowego. Należy zrozumieć, w jaki sposób informacja przekazywana przez komputer może wesprzeć proces poznawania otoczenia. W niniejszym rozdziale przedstawiono perspektywę osób niewidomych w kontekście rozpoznawania obiektów przestrzennych, a następnie omówiono wybrane technologie wspomagające osoby z niepełnosprawnością wzroku i metody komputerowej detekcji obiektów. Szczególną uwagę poświęcono rodzinie modeli YOLO, które są wykorzystywane w niniejszej pracy. W kolejnych podrozdziałach przedstawiono metryki wykorzystywane do oceny jakości detekcji obiektów oraz podsumowano analizę tematu.

2.1 Perspektywa osób niewidomych w rozpoznawaniu obiektów przestrzennych

Przy projektowaniu systemu przeznaczonego dla osób niewidomych należy wziąć pod uwagę różnice w percepcji przestrzennej pomiędzy osobami widzącymi a niewidomymi. W literaturze zagadnienie to jest analizowane zarówno z perspektywy technicznej, psychologicznej oraz pedagogicznej. Badania ukazują percepcję osób niewidomych, pozwalając lepiej zrozumieć ich sposób poznawania otoczenia. Costa et al. w swojej pracy pokazują na przykładzie badanego uczestnika, że rozpoznawanie obiektu jest całym procesem. W przypadku osób widzących spojrzenie zazwyczaj pozwala zrozumieć obiekt całościowo, natomiast w wypadku osób niewidomych poznanie odbywa się sekwencyjnie, etapami. Dlatego duże znaczenie mają cechy obiektu, które są wyraźnie dostępne w eksploracji dotykowej: prostota, regularność, krawędzie oraz faktura; cechy te wspierają budowę mentalnej reprezentacji przestrzennej obiektu. Osoba niewidoma może opierać ją nie tylko na aktualnej informacji dotykowej, ale również na wcześniejszych doświadczeniach, kontekście i wiedzy o świecie. Autorzy ukazują, że brak wzroku nie oznacza prostego zastąpienia go przez inne zmysły - dotyk, słuch, pamięć i doświadczenia dostarczają informacji innego rodzaju oraz są wykorzystywane w odmienny sposób. Wiedząc o tym, projektowany system powinien nie tylko poprawnie rozpoznawać obiekt, ale również wspierać użytkownika w jego zrozumieniu. [2]

Kolejną pracą, szczególnie pokazującą jak osoba niewidoma uczy się matematyki i w jaki sposób komunikuje się z nauczycielem, jest artykuł autorstwa Figueiras i Arcavi. Jest on w głównej mierze obserwacją lekcji prowadzonych przez niewidomego nauczyciela dla trzech uczniów, z czego dwóch było w pełni niewidomych, a jeden miał częściową utratę wzroku. Szczególnie ciekawe okazują się zapisy rozmów pomiędzy nauczycielem, a uczniami, które ukazują wcześniej wspomniane etapowe poznawanie obiektu. Przy budowie stożka nauczyciel bazuje na wcześniejszych doświadczeniach i wiedzy uczniów, a także na ich wyobrażeniach przestrzennych. Kolejna część - mimo, że nie związana ściśle z bryłami 3D - pokazuje w jaki sposób osoba niewidoma rozpoznaje części paraboli i jak wyznacza jej pierwiastki. Autorzy dostarczają również tabelę porównującą w jaki sposób uczniowie widzący i niewidzący konstruują wykres paraboli. W obu przypadkach uczestnicy rozwiązują równanie paraboli, ale zaznaczają, że badani niewidomi przed tym znajdują pierwiastek i określają symetrię. Następnie wszyscy uczniowie obliczają numerycznie wartości funkcji w ten sam sposób. Sam fakt tego, że osoby niewidome przed przystąpieniem do wykonywania obliczeń analizują kształt paraboli wnioskując, że jawnie korzysta z wiedzy o kształcie i wcześniejszych doświadczeniach z takimi obiektami. Takie rozumowanie nie jest wymagane w przypadku osób widzących, które od razu widzą cechy charakterystyczne wykresu. Te informacje wnoszą do projektu systemu, że samo rozpoznawanie obiektu nie jest wystarczające - należy dostarczyć użytkownikowi również informacji

o jego cechach charakterystycznych. [4]

[4]

Are we aware of the needs of students with visual impairment? A study on challenges and instructional needs in science lessons

Typ artykułu: bardziej pedagogiczny / dydaktyka nauk przyrodniczych / accessibility w edukacji. To nie jest artykuł techniczny ani psychologiczny. Jest jednak dość przydatny do Twojego podrozdziału, bo dotyczy tego, jak uczniowie z niepełnosprawnością wzroku radzą sobie z pojęciami naukowymi, kształtami, reprezentacjami wizualnymi i materiałami przestrzennymi. Badanie jest jakościowe: 13 uczniów z niepełnosprawnością wzroku i 10 nauczycieli, wywiady oraz obserwacje lekcji przyrody/nauk ścisłych.

Najważniejszy wniosek w kontekście Twojej pracy jest taki, że jednym z głównych problemów uczniów z niepełnosprawnością wzroku było tworzenie w umyśle wyobrażeń kształtów i pojęć przestrzennych. W artykule uczniowie wskazywali trudności z wizualizacją kształtów, rozumieniem figur oraz pytaniami opartymi na kształtach. Jeden z cytowanych uczniów mówi wręcz, że gdy słyszy np. „drzewo” albo „piramida”, nie zawsze potrafi utworzyć w umyśle odpowiadający temu obraz. To mocno wspiera tezę, że dla osoby niewidomej samo słowne nazwanie obiektu może nie wystarczyć — potrzebne są konkretne, dotykowe lub wielomodalne reprezentacje, które pomagają zbudować model mentalny obiektu. W Twoim projekcie można to odnieść do brył 3D: system powinien nie tylko rozpoznawać klasę obiektu, ale też wspierać użytkownika w zrozumieniu jego cech przestrzennych, np. czy ma płaskie ściany, krawędzie, zaokrąglenia albo wydłużony kształt.

Drugi ważny wniosek dotyczy tego, że nauka oparta głównie na mówieniu, podręczniku i materiałach wizualnych jest dla takich uczniów niewystarczająca. Z obserwacji wynikało, że lekcje były często prowadzone metodą wykładową, z użyciem smartboardu, filmów lub podręcznika, a rzadko wykorzystywano eksperymenty, pracę z konkretnymi obiektami, materiały 3D czy aktywności angażujące uczniów. Jednocześnie uczniowie sami deklarowali, że chcieliby więcej eksperymentów, projektów i aktywności praktycznych. To można wykorzystać jako argument, że osoby niewidome potrzebują aktywnego, dotykowego kontaktu z obiektem, a technologie wspomagające powinny być projektowane tak, aby wspierały eksplorację, a nie zastępowały ją biernym opisem. Ograniczenie: artykuł dotyczy edukacji szkolnej i lekcji science, więc nie jest bezpośrednio o systemach rozpoznawania obiektów, ale bardzo dobrze uzasadnia potrzebę materialnych, przestrzennych i dotykowych reprezentacji w rozumieniu kształtów. [5]

Understanding Visual Arts Experiences of Blind People

Typ artykułu: bardziej HCI / accessibility / UX, czyli empiryczno-projektowy. Nie jest to artykuł stricte techniczny od strony algorytmów ani czysto psychologiczny, ale mocno dotyka perspektywy użytkownika, sposobów odbioru informacji wizualnych bez wzroku oraz projektowania technologii wspomagających. Badanie opiera się na 15 wywiadach z

osobami niewidomymi oraz ankiecie z 220 respondentami, więc jest bardzo przydatne do uzasadnienia potrzeb użytkownika, a mniej do opisu konkretnej metody rozpoznawania obiektów.

Najważniejszy wniosek do Twojej pracy jest taki, że osoby niewidome nie potrzebują wyłącznie samego „dostępu do obrazu”, ale dobrze dobranej formy informacji. Artykuł pokazuje, że różne modalności spełniają różne funkcje: dotyk lepiej wspiera rozumienie kształtu, formy, położenia i szczegółów przestrzennych, natomiast opis audio lepiej przekazuje tło, kontekst, historię albo znaczenie obiektu. To dobrze pasuje do Twojego systemu, bo sugeruje, że sama etykieta klasy, np. „sześcian” lub „stożek”, może być niewystarczająca. Informacja zwrotna powinna być raczej warstwowa: najpierw prosta identyfikacja obiektu, a potem ewentualnie dodatkowe cechy, takie jak krawędzie, powierzchnie, orientacja, podobieństwo do innych brył albo stopień pewności rozpoznania.

Drugi ważny wniosek dotyczy personalizacji i różnic między użytkownikami. Autorzy pokazują, że preferencje zależą m.in. od tego, czy dana osoba jest niewidoma od urodzenia, czy utraciła wzrok później. Osoby niewidome od urodzenia częściej preferowały dostęp dotykowy, natomiast osoby, które utraciły wzrok później, częściej korzystały z wyobrażeń opartych na wcześniejszej pamięci wzrokowej i były bardziej otwarte na dostęp zdalny lub cyfrowy. W kontekście Twojej pracy warto z tego wyciągnąć, że system nie powinien być projektowany według zasady „jeden sposób komunikacji dla wszystkich”. Lepiej uzasadnić potrzebę prostego, elastycznego feedbacku głosowego, możliwości dopasowania poziomu szczegółowości oraz unikania subiektywnych opisów. Artykuł mocno wspiera też myśl, że technologie wspomagające powinny zmniejszać zależność od osób widzących, ale jednocześnie nie ignorować społecznego aspektu poznawania — rozmowy, pytań, potwierdzania hipotez i komfortu użytkownika. [6]

Visually Impaired Students' and Their Teacher's Perceptions of the English Teaching and Learning Process

Typ artykułu: bardziej pedagogiczny / edukacyjny, jakościowy. To nie jest tekst techniczny ani stricte psychologiczny. Bada doświadczenia dwóch uczniów z niepełnosprawnością wzroku i ich nauczycielki w procesie nauki języka angielskiego, więc do Twojej pracy nadaje się raczej jako źródło o potrzebach użytkowników, adaptacji materiałów i roli komunikacji, a nie bezpośrednio o rozpoznawaniu brył. Trzeba też uważać z uogólnianiem, bo próba jest bardzo mała: dwóch uczniów i jedna nauczycielka.

Najważniejsze, co można z tego wyciągnąć do podrozdziału o perspektywie osób niewidomych, to fakt, że skuteczność nauki i poznawania zależy nie tylko od samej obecności osoby niewidomej w danym środowisku, ale od realnego dostosowania metod, materiałów i komunikacji. W artykule pojawiają się problemy bardzo przydatne do Twojego kontekstu: brak specjalistycznych materiałów, ograniczona znajomość Braille'a przez nauczyciela, trudności komunikacyjne, większa czasochłonność wykonywania zadań oraz potrzeba wsparcia ze strony innych osób. W pracy możesz to wykorzystać jako argument, że system

wspomagający osobę niewidomą powinien minimalizować zależność od otoczenia, dawać jasną informację zwrotną i brać pod uwagę, że użytkownik może potrzebować więcej czasu na eksplorację oraz zrozumienie obiektu.

Drugi przydatny wniosek dotyczy znaczenia dotyku i materiałów dostępnych sensorycznie. Autorzy wskazują na użycie wypukłych kart, dużego druku, Braille’a, dodatkowego czasu, pracy z rówieśnikami i materiałów przygotowanych specjalnie pod potrzeby ucznia. Dla Twojej pracy najbliższy tematowi jest fragment o pamięci dotykowej i materiałach w reliefie: dotyk może wspierać budowanie reprezentacji obiektu, ale wymaga odpowiednio przygotowanych bodźców i spójnego sposobu komunikacji. W kontekście systemu rozpoznawania obiektów 3D można więc ostrożnie wnioskować, że sama detekcja obiektu nie wystarcza — ważne jest, jak wynik zostanie przekazany użytkownikowi: prosto, konsekwentnie, najlepiej w sposób wspierający jego własną eksplorację dotykową, a nie zastępujący ją arbitralnym opisem. [1]

Jasne — ja bym ten podrozdział ułożył od najbardziej ogólnego mechanizmu poznawania przestrzennego do wniosków projektowych dla Twojego systemu. Nie zaczynałbym od technologii, tylko od tego, jak osoba niewidoma tworzy reprezentację obiektu.

Proponowana kolejność i rola artykułów:

1. Costa, Lima, Biembengut — Spatial perception of a blind person To dałbym jako najważniejszy artykuł otwierający podrozdział. Najlepiej nadaje się do opisanego mechanizmu: osoba niewidoma poznaje obiekt/przestrzeń etapowo, przez dotyk, hipotezy, wcześniejsze doświadczenia i budowanie modelu mentalnego. To może być fundament całego 2.1.

2. Figueiras, Arcavi — Learning to see: the viewpoint of the blind Dałbym zaraz po pierwszym, jako teoretyczne wzmocnienie tezy, że wizualizacja nie oznacza wyłącznie widzenia. Ten tekst dobrze pokazuje, że osoba niewidoma może tworzyć reprezentacje przestrzenne, ale wymaga to większej jawności opisu, uwagi na relacje przestrzenne i łączenia informacji dotykowych z werbalnymi.

3. Güler, Ürey — Are we aware of the needs of students with visual impairment? To wykorzystałbym jako mocne wsparcie praktyczne: uczniowie z niepełnosprawnością wzroku mają trudności z wyobrażaniem sobie kształtów, figur i pojęć przestrzennych, zwłaszcza gdy są one przekazywane głównie werbalnie albo przez materiały wizualne. Ten artykuł dobrze uzasadnia potrzebę obiektów 3D, modeli, dotyku i aktywnej eksploracji.

4. Li et al. — Understanding Visual Arts Experiences of Blind People Ten artykuł dałbym później, jako pomost do projektowania systemu wspomagającego. Nie jest o bryłach ani edukacji science, ale bardzo dobrze pokazuje, że osoby niewidome potrzebują informacji wielomodalnej, kontekstowej i dopasowanej do użytkownika. Można go użyć przy wniosku, że sam komunikat „to jest sześcian” może być za ubogi — lepszy jest feedback warstwowy: nazwa, cechy, relacje, orientacja, możliwość doprecyzowania.

5. Cando Guanoluisa et al. — Visually Impaired Students’ and Their Teacher’s Percep-

tions... Ten potraktowałbym jako artykuł pomocniczy, najmniej bezpośredni dla Twojego tematu. Przydaje się do pokazania, że skuteczne wsparcie osób niewidomych wymaga adaptacji materiałów, jasnej komunikacji, dodatkowego czasu, Braille’a, materiałów wypukłych i wsparcia środowiska. Nie robiłbym z niego głównego źródła do rozpoznawania obiektów, tylko użył jako dodatkowego argumentu o potrzebie dostosowania sposobu przekazywania informacji.

Ważność dla podrozdziału: Najważniejsze źródła: Costa et al. i Figueiras & Arcavi — one bezpośrednio wspierają opis percepcji, wizualizacji i budowania reprezentacji przestrzennej bez wzroku.

Bardzo przydatne źródło praktyczne: Güler & Ürey — pokazuje konkretny problem z kształtami, pojęciami przestrzennymi i brakiem materiałów 3D.

Źródło projektowe/technologiczne: Li et al. — dobre do przejścia od analizy problemu do wymagań wobec systemu.

Źródło uzupełniające: Cando Guanoluisa et al. — użyć oszczędnie, jako potwierdzenie problemów z adaptacją materiałów i komunikacją.

W skrócie: najpierw mechanizm poznawania, potem trudności z kształtami, potem potrzeba materiałów dotykowych i wielomodalnych, na końcu wnioski projektowe dla systemu. Dzięki temu podrozdział nie będzie wyglądał jak przypadkowy przegląd artykułów, tylko jak logiczne dojście do tego, dlaczego Twój system ma sens.

2.2 Technologie wspomagające osoby z niepełnosprawnością wzroku

Aplikacje mobilne, systemy wearable, kamery, czujniki głębi, audio feedback.

2.3 Problem rozpoznawania obiektów 3D w interakcji dotykowej

Tutaj opisuję, że użytkownik nie tylko patrzy kamerą na scenę, ale dotyka obiektu, więc problem jest trochę inny niż klasyczna detekcja przedmiotów w pomieszczeniu.

2.4 Metody detekcji obiektów w obrazach

YOLO, SSD, Faster R-CNN, Mask R-CNN — ogólnie, bez przesadnego grzebania.

2.5 Rodzina modeli YOLO

Tu najwięcej, bo tego używasz. Architektura ogólnie, zalety: szybkość, detekcja w czasie rzeczywistym, różne rozmiary modeli.

2.6 Wykorzystanie danych RGB, głębi i LiDAR w rozpoznawaniu obiektów

Tu mogę opisać, dlaczego LiDAR był rozważany, ale w praktyce ma ograniczenia przy małych obiektach i małych odległościach.

2.7 Metryki oceny detekcji obiektów

Ocena modeli detekcji obiektów wymaga zastosowania odpowiednich metryk, które pozwalają na porównanie uzyskanych wyników. Metryki te powinny uwzględniać zarówno poprawność klasyfikacji, jak i dokładność lokalizacji obiektu na obrazie. Przeciwnie do klasyfikacji obrazów, przy detekcji nie wystarczy, aby model poprawnie rozpoznał klasę obiektu. Równie istotne jest, aby poprawnie wyznaczył ramkę ograniczającą wokół wykrytego obiektu. Jedną z najczęściej stosowanych metryk jest IoU (ang. *Intersection over Union*), określająca stopień pokrycia między ramką obiektu przewidywaną przez model a ramką rzeczywistą [8]. Wartość IoU obliczana jest jako stosunek pola części wspólnej obu ramek do pola ich części łącznej:

$$IoU = \frac{|B_p \cap B_{gt}|}{|B_p \cup B_{gt}|}, \quad (2.1)$$

gdzie B_p jest ramką przewidywaną przez model, a B_{gt} jest ramką referencyjną (ang. *ground truth*). Im większa wartość IoU, tym lepsze dopasowanie ramki przewidywanej do ramki rzeczywistej. W praktyce najczęściej stosuje się progi, np. $IoU \geq 0.5$, aby zdecydować, czy dana detekcja może być uznana za poprawną. Próg ten został wykorzystany w wielu klasycznych procedurach oceny detekcji, takich jak PASCAL VOC [3], i jest nadal powszechnie stosowany w wielu benchmarkach. Na podstawie wartości IoU oraz zgodności klasy obiektu możliwe jest przypisanie wyników detekcji do jednej z kategorii: prawdziwych pozytywów (TP, ang. *true positive*), fałszywych pozytywów (FP, ang. *false positive*) i fałszywych negatywów (FN, ang. *false negative*). Detekcja jest traktowana jako TP, jeżeli model poprawnie rozpoznał klasę obiektu, a przewidywana ramka spełnia zadany próg IoU względem ramki referencyjnej. FP to detekcja błędna w której model przewidział klasę obiektu, ale nie spełnił progu IoU lub przewidziana klasa była błędna. FN natomiast to sytuacja, w której model nie wykrył obiektu, który rzeczywiście był na obrazie.

Jedną z podstawowych metryk oceny jest precyzja (ang. *precision*), określająca udział poprawnych detekcji modelu wśród wszystkich detekcji, jakie zwrócił:

$$Precision = \frac{TP}{TP + FP}. \quad (2.2)$$

Wysoka precyzja oznacza, że model generuje niewiele fałszywych pozytywów. Drugą, powiązaną z nią metryką, jest czułość (ang. *recall*), określająca, jaki jest udział poprawnych detekcji wśród wszystkich rzeczywistych obiektów:

$$Recall = \frac{TP}{TP + FN}. \quad (2.3)$$

Obie metryki pozostają ze sobą w relacji kompromisu, ponieważ zwiększenie progu pewności detekcji może ograniczyć liczbę fałszywych pozytywów, ale jednocześnie prowadzić do pominięcia części rzeczywistych obiektów. Z kolei obniżenie tego progu może zwiększyć liczbę detekcji, ale równocześnie powodować wzrost liczby fałszywych detekcji. Z tego względu, przy analizie detektorów często łączy się je w jedną metrykę – krzywą PR (precyzja-czułość, ang. *precision-recall curve*), przedstawiającą zależność pomiędzy nimi dla różnych wartości progu decyzyjnego. Na jej podstawie wyznacza się metrykę AP (ang. *Average Precision*), odpowiadającą polu pod krzywą PR.

W przypadku detekcji wieloklasowej używa się średniej wartości AP obliczonej dla wszystkich klas, określanej jako mAP (ang. *mean Average Precision*):

$$mAP = \frac{1}{N} \sum_{i=1}^N AP_i, \quad (2.4)$$

gdzie N jest liczbą klas, a AP_i jest wartością AP dla i -tej klasy. W praktyce najczęściej wykorzystuje się dwie wersje tej metryki: mAP_{50} , gdzie detekcję uznaje się za poprawną przy progu $IoU \geq 0.5$, oraz mAP_{50-95} , gdzie wynik jest uśredniany dla progów IoU z zakresu od 0.5 do 0.95. Pierwsza z nich jest bardziej liberalna i pozwala określić ogólną zdolność modelu do wykrycia obiektu. Druga natomiast jest bardziej rygorystyczna, ponieważ wymaga dokładniejszego dopasowania ramek ograniczających, dzięki czemu lepiej pokazuje zarówno skuteczność klasyfikacji, jak i lokalizacji obiektu. Uśrednianie wyników dla wielu progów zostało szeroko zastosowane m. in. w metodyce oceny detekcji zbioru Microsoft COCO [7] i jest obecnie standardem w wielu benchmarkach detekcji obiektów.

Dodatkowo, w pracy wykorzystano metrykę $F1$ -score, będącą średnią harmoniczną precyzji i czułości:

$$F1 = 2 \cdot \frac{P \cdot R}{P + R}, \quad (2.5)$$

gdzie P jest precyzją, a R jest czułością. Metryka ta umożliwia przedstawienie kompromisu pomiędzy liczbą fałszywych detekcji a liczbą pominiętych obiektów. Może być szczególnie przydatna, gdy sama precyzja lub czułość nie dają pełnego obrazu jakości modelu. W niniejszej pracy metrykę $F1$ -score wykorzystano jako metrykę pomocniczą

względem podstawowych metryk $mAP50$ i $mAP50 - 95$, aby lepiej zrozumieć kompromis pomiędzy precyzją a czułością w kontekście detekcji obiektów dotykanych przez użytkownika.

Oprócz wartości liczbowych wykorzystano również macierze pomyłek (ang. *confusion matrix*), pozwalające przeanalizować, które klasy obiektów są najczęściej mylone przez model. Są one przedstawiane w formie tabel, w których jedna oś odpowiada rzeczywistym klasom, a druga klasom przewidywanym przez model. Dla dobrze działającego modelu większość wartości powinna znajdować się na przekątnej macierzy, co wskazuje na poprawną klasyfikację obiektów. Macierze pomyłek są szczególnie istotne przy rozpoznawaniu brył geometrycznych o podobnych kształtach, np. sześcianu i prostopadłościanu, ponieważ sama wartość mAP nie wskazuje bezpośrednio, pomiędzy którymi klasami model popełnia najwięcej błędów. Analiza macierzy pomyłek może również pomóc w identyfikacji problemów z danymi treningowymi, np. niedostatecznej liczby przykładów dla wybranych klas lub błędów w oznaczeniach.

2.8 Podsumowanie analizy tematu

Najważniejsze: z literatury wynika, że detekcja obiektów w czasie rzeczywistym jest sensownym kierunkiem, ale Twoja nisza to rozpoznawanie konkretnych dotykanych brył 3D w kontrolowanym scenariuszu.

Rozdział 3

Koncepcja systemu rozpoznawania dotykanych obiektów 3D

To odpowiada wymaganej części „przedmiot pracy”: rozwiązanie zaproponowane przez dyplomanta, analiza teoretyczna, uzasadnienie metod, algorytmów i narzędzi.

3.1 Założenia funkcjonalne i нефunkcjonalne

Funkcjonalne: akwizycja obrazu, przesyłanie klatek, detekcja obiektu, informacja zwrotna. Niefunkcjonalne: możliwie niskie opóźnienie, prostota użycia, mobilność, powtarzalność badań.

3.2 Architektura systemu

iPhone → przesyłanie obrazu/WebSocket → serwer Python → model YOLO → wynik → feedback.

3.3 Dobór klas rozpoznawanych obiektów

Cube, sphere, cylinder, cuboid, tetrahedron, cone. Tu warto uzasadnić, że są to podstawowe bryły geometryczne, możliwe do wydruku 3D i łatwe do kontrolowanego oznaczania.

3.4 Uzasadnienie wyboru metody detekcji

Dlaczego YOLO: szybkość, popularność, gotowe narzędzia treningowe, możliwość porównania wariantów n/s, metryki.

3.5 Przepływ danych w systemie

Od obrazu z telefonu, przez detekcję, po komunikat dla użytkownika.

3.6 Ograniczenia przyjętej koncepcji

Na przykład: kontrolowany zestaw obiektów, zależność od oświetlenia, ograniczony dataset, problem z generalizacją na inne dłonie/osoby/tła.

Rozdział 4

Implementacja systemu

Tu opisuję konkretną robotę inżynierską. Nie za dużo kodu w głównym tekście — raczej architektura, moduły, decyzje. Opis interfejsów aplikacji i środowisk projektowania lepiej dawać jako załącznik, bo wymagania sugerują, że takie rzeczy powinny iść do załącznika.

4.1 Środowisko programistyczne i wykorzystane narzędzia

Python, PyTorch/Ultralytics, OpenCV, Swift/iOS, ARKit, WebSocket, CVAT/Robo-flow/HF — tylko te, które finalnie zostaną.

4.2 Moduł akwizycji danych obrazowych

Jak pozyskuję obraz z telefonu / nagrań / streamu.

4.3 Moduł komunikacji klient-serwer

WebSocket, przesyłanie klatek, format danych, obsługa połączenia.

4.4 Moduł detekcji obiektów

Ładowanie modelu, inferencja, wynik detekcji, progi confidence.

4.5 Moduł informacji zwrotnej dla użytkownika

Komunikaty audio / tekstowe / docelowe zachowanie aplikacji.

4.6 Organizacja kodu i plików projektu

Krótko, bez robienia instrukcji obsługi. Dokładna dokumentacja może iść do załącznika albo plików dodatkowych.

Rozdział 5

Zbiór danych i metodyka badań

To jest bardzo ważny rozdział, bo wymagania kładą nacisk na metodykę, dane, powtarzalność i naukową analizę wyników. Badania powinny być przeprowadzone „tak jak jest przyjęte w ujęciu naukowym”, np. z zapewnieniem powtarzalności testów.

5.1 Charakterystyka zbioru danych

Liczba klas, liczba obrazów, rozdzielczość, źródło danych, przykładowe obrazy.

5.2 Proces pozyskiwania i oznaczania danych

Nagrania, ekstrakcja klatek, anotacje, negatywne próbki, puste etykiety.

5.3 Podział danych na zbiory treningowy, walidacyjny i testowy

Train/val/test. Tu trzeba bardzo jasno wyjaśnić, jak dzielić dane, żeby recenzent nie zarzucił przecieku danych.

5.4 Warianty danych wejściowych

Kolor, grayscale, ewentualne filtry/normalizacja. To będzie dobre miejsce na porównanie „kolor vs grayscale”.

5.5 Konfiguracja treningu modeli

Modele, rozmiar obrazu, batch, liczba epok, patience, pretrained/from scratch, sprzęt GPU.

5.6 Metryki oceny

Precision, recall, mAP50, mAP50-95, macierz pomyłek, czas inferencji/FPS, zużycie pamięci.

Do oceny modeli wykorzystano metryki zwracane przez narzędzie Ultralytics YOLO: precision, recall, mAP50 oraz mAP50-95. Dodatkowo na podstawie wartości precision i recall obliczono F1-score. Wyniki zapisywano w pliku results.csv, natomiast przebiegi metryk oraz macierze pomyłek analizowano na podstawie plików generowanych po zakończeniu treningu i walidacji. [9]

5.7 Procedura eksperymentalna

Czyli dokładnie: jakie modele trenowano, na jakich danych, jakie wyniki zbierano, jak porównywano.

Rozdział 6

Wyniki badań i ich analiza

To powinien być osobny rozdział, nie mieszany z metodyką. Wymagania mówią, że badania mają zawierać prezentację wyników, opracowanie i poszerzoną dyskusję wyników oraz wnioski.

6.1 Wyniki uczenia modeli YOLO

Tabele z najlepszymi wynikami: model, imgsz, precision, recall, mAP50, mAP50-95, f1, czas, pamięć.

6.2 Porównanie wariantów modeli

YOLO n vs s, ewentualnie inne warianty.

6.3 Wpływ reprezentacji obrazu na skuteczność detekcji

Kolor vs grayscale. To może być jeden z ciekawszych fragmentów pracy.

6.4 Analiza błędów klasyfikacji i detekcji

Macierze pomyłek, najczęściej mylone klasy, np. cube/sphere/cuboid itd.

6.5 Ocena działania systemu w scenariuszu użytkowym

Nie tylko mAP, ale też: czy system nadaje się do użycia, jakie ma opóźnienia, co działa, co nie działa.

6.6 Dyskusja ograniczeń wyników

Mały/średni dataset, kontrolowane warunki, jedna osoba w części danych, zależność od tła/oświetlenia, możliwe przeuczenie, generalizacja.

Rozdział 7

Podsumowanie i wnioski końcowe

7.1 Podsumowanie wykonanych prac

Co zostało zrobione: dataset, modele, system, eksperymenty.

7.2 Ocena realizacji celu pracy

Wprost: czy cel został osiągnięty, w jakim zakresie, z jakimi ograniczeniami.

7.3 Najważniejsze wnioski

Np. detekcja obiektów jest skuteczna, ale ma ograniczenia, np. w przypadku małych obiektów, podobnych kształtów, zależności od tła i oświetlenia.

7.4 Możliwe kierunki rozwoju

Większy dataset, więcej osób, więcej obiektów, integracja LiDAR/RGB-D, inference lokalnie na iPhone, lepszy feedback audio, testy z użytkownikami.

Bibliografia

- [1] Fabiola Cando-Guanoluisa, Lesly Claudio, Dylan Cevallo, Carlos Colcha, Silvia Taipi i Grecia Pilatas. „Visually Impaired Students’ and Their Teacher’s Perceptions of the English Teaching and Learning Process”. W: *Mextesol Journal* 46 (sty. 2023), s. 1–14. DOI: 10.61871/mj.v46n4-3.
- [2] João Francisco Staffa Costa, V. M. R. Lima i M. S. Biembengut. „Spatial perception of a blind person: interactions and experiences”. W: *Brazilian Journal of Science Teaching and Technology, Ponta Grossa* 16 (2023), s. 1–20. DOI: 10.3895/rbect.v16n1.13944.
- [3] Mark Everingham, Luc Van Gool, Christopher K. I. Williams, John Winn i Andrew Zisserman. „The PASCAL Visual Object Classes (VOC) Challenge.” W: *International Journal of Computer Vision* 88.2 (2010), s. 303–338. DOI: 10.1007/s11263-009-0275-4.
- [4] Lourdes Figueiras i Abraham Arcavi. „Learning to See: The Viewpoint of the Blind”. W: *Selected Regular Lectures from the 12th International Congress on Mathematical Education*. Red. Sung Je Cho. Cham: Springer International Publishing, 2015, s. 175–186. ISBN: 978-3-319-17187-6. DOI: 10.1007/978-3-319-17187-6_10.
- [5] Maşide Güler i Mustafa Ürey. „Are we aware of the needs of students with visual impairment? A study on challenges and instructional needs in science lessons”. W: *Journal of Pedagogical Sociology and Psychology* 7 (2 2025), s. 53–70. DOI: 10.33902/jpsp.202529253.
- [6] Franklin Mingzhe Li, Lotus Zhang, Maryam Bandukda, Abigale Stangl, Kristen Shinohara, Leah Findlater i Patrick Carrington. „Understanding Visual Arts Experiences of Blind People”. W: *Proceedings of the 2023 CHI Conference on Human Factors in Computing Systems*. CHI ’23. Hamburg, Germany: Association for Computing Machinery, 2023. ISBN: 9781450394215. DOI: 10.1145/35444548.3580941.
- [7] Tsung-Yi Lin, Michael Maire, Serge J. Belongie, James Hays, Pietro Perona, Deva Ramanan, Piotr Dollár i C. Lawrence Zitnick. „Microsoft COCO: Common Objects in Context”. W: *Computer Vision – ECCV 2014*. T. 8693. Lecture Notes in Computer Science. Springer, 2014, s. 740–755. DOI: 10.1007/978-3-319-10602-1_48.

- [8] Rafael Padilla, Wesley L. Passos, Thadeu L. B. Dias, Sergio L. Netto i Eduardo A. B. da Silva. „A Comparative Analysis of Object Detection Metrics with a Companion Open-Source Toolkit”. W: *Electronics* 10.3 (2021). ISSN: 2079-9292. DOI: 10.3390/electronics10030279.
- [9] Ultralytics. *Performance Metrics Deep Dive*. YOLO Performance Metrics documentation. 12 list. 2023. URL: <https://docs.ultralytics.com/guides/yolo-performance-metrics/> (term. wiz. 17.12.2025).

Dodatki

Dokumentacja techniczna

Spis skrótów i symboli

IoU Intersection over Union – miara stopnia pokrycia ramki przewidywanej przez model z ramką referencyjną.

TP True Positive – prawdziwy pozytywny, poprawnie wykryty obiekt.

FP False Positive – fałszywy pozytywny, błędna detekcja zwrócona przez model.

FN False Negative – fałszywy negatywny, obiekt rzeczywisty niewykryty przez model.

PR Precision-Recall – zależność między precyzją a czułością

AP Average Precision – średnia precyzja wyznaczana na podstawie krzywej precision-recall.

mAP mean Average Precision – średnia wartość AP obliczana dla wszystkich klas.

F1 F1-score – średnia harmoniczna precyzji i czułości.

VOC Visual Object Classes – zbiór nazw benchmarku PASCAL VOC wykorzystywanego w ocenie detekcji obiektów.

COCO Common Objects in Context – nazwa zbioru i benchmarku Microsoft COCO.

Lista dodatkowych plików, uzupełniających tekst pracy (jeżeli dotyczy)

W systemie do pracy dołączono dodatkowe pliki zawierające:

- źródła programu,
- zbiory danych użyte w eksperymentach,
- film pokazujący działanie opracowanego oprogramowania lub zaprojektowanego i wykonanego urządzenia,
- itp.

Spis rysunków

Spis tabel